

تمرین‌ها را در یک فایل پایتون با فرمت زیر ارسال کنید. نام فایل پایتون شماره دانشجویی باشد. فایل زیپ ارسال کنید.

هدف: کار با پکیج نام پای

تمرین ۱. تابع $\text{classify}(\text{data}, k)$ بنویسید که دو پارامتر data و k دریافت می‌کند. منظور از data یک ماتریس n در m است که n (تعداد سطر) نمونه داده‌ها و m (ستون) تعداد ویژگی است و k یک عدد (تعداد گروه) است. هدف این است که داده‌ها را به k گروه تقسیم‌بندی کنیم. خروجی این تابع یک ماتریس n در k است که نشان می‌دهد هر نمونه به کدام خوشه تعلق دارد. همانند شکل زیر:

	Cluster1	Cluster2	Cluster3	...
n1	0	0	1	...
n2	1	0	0	...
n3	0	0	1	...
...	...	...	...	...

نکته. این تمرین اختیاری و ۲ نمره است.

مثالی از الگوریتم

هدف این است که هشت نمونه داده (data) زیر را سه گروه (k) دسته‌بندی کنیم:

2 10
2 5
8 4
5 8
7 5
6 4
1 2
4 9

نمونه‌ها بالا به صورت زیر نام گذاری کردیم:

$A_1(2, 10)$ $A_2(2, 5)$ $A_3(8, 4)$ $A_4(5, 8)$ $A_5(7, 5)$ $A_6(6, 4)$ $A_7(1, 2)$ $A_8(4, 9)$

فاصله بین دو نقطه $a=(x_1, y_1)$ و $b=(x_2, y_2)$ به صورت زیر محاسبه می‌شود:

$$\rho(a, b) = |x_2 - x_1| + |y_2 - y_1|$$

الگوریتم زیر را استفاده می‌کنیم تا مراکز خوشه‌ها پس از دومین تکرار پیدا کنیم:

راه حل:

Iteration 1

		(2, 10)	(5, 8)	(1, 2)	
	Point	Dist Mean 1	Dist Mean 2	Dist Mean 3	Cluster
A1	(2, 10)				
A2	(2, 5)				
A3	(8, 4)				
A4	(5, 8)				
A5	(7, 5)				
A6	(6, 4)				
A7	(1, 2)				
A8	(4, 9)				

ابتدا ما تمام نمونه‌ها در جدول بالا لیست کرده‌ایم. مراکز اولیه خوشه رندوم از میان نمونه‌ها انتخاب می‌شوند. فرض کنید سه مرکز خوشه زیر انتخاب شده است

(2, 10), (5, 8), (1, 2).

در ادامه فاصله تمامی مراکز از نمونه (۲،۱۰) محاسبه می‌شود:

point	mean1
x1, y1	x2, y2
(2, 10)	(2, 10)
$\rho(a, b) = x2 - x1 + y2 - y1 $	
$\rho(\text{point}, \text{mean1}) = x2 - x1 + y2 - y1 $	
$= 2 - 2 + 10 - 10 $	
$= 0 + 0$	
$= 0$	
point	mean2
x1, y1	x2, y2
(2, 10)	(5, 8)
$\rho(a, b) = x2 - x1 + y2 - y1 $	
$\rho(\text{point}, \text{mean2}) = x2 - x1 + y2 - y1 $	
$= 5 - 2 + 8 - 10 $	
$= 3 + 2$	
$= 5$	
point	mean3
x1, y1	x2, y2
(2, 10)	(1, 2)
$\rho(a, b) = x2 - x1 + y2 - y1 $	
$\rho(\text{point}, \text{mean2}) = x2 - x1 + y2 - y1 $	
$= 1 - 2 + 2 - 10 $	
$= 1 + 8$	
$= 9$	

ما جدول بالا به صورت زیر پر می‌کنیم. چون فاصله از مرکز خوشه اول کمترین است اولین نمونه به خوشه اول تعلق می‌یابد.

Iteration 1

		(2, 10)	(5, 8)	(1, 2)	
	Point	Dist Mean 1	Dist Mean 2	Dist Mean 3	Cluster
A1	(2, 10)	0	5	9	1
A2	(2, 5)				
A3	(8, 4)				
A4	(5, 8)				
A5	(7, 5)				
A6	(6, 4)				
A7	(1, 2)				
A8	(4, 9)				

بنابراین نمونه اول به خوشه ۱ تعلق می‌یابد:

Cluster 1
(2, 10)

Cluster 2

Cluster 3

برای نمونه بعدی (۲،۵) نیز فاصله از مراکز خوشه‌ها را محاسبه می‌کنیم:

point x1, y1 (2, 5)	mean1 x2, y2 (2, 10)
$\rho(a, b) = x_2 - x_1 + y_2 - y_1 $ $\rho(\text{point}, \text{mean1}) = x_2 - x_1 + y_2 - y_1 $ $= 2 - 2 + 10 - 5 $ $= 0 + 5$ $= 5$	
point x1, y1 (2, 5)	mean2 x2, y2 (5, 8)
$\rho(a, b) = x_2 - x_1 + y_2 - y_1 $ $\rho(\text{point}, \text{mean2}) = x_2 - x_1 + y_2 - y_1 $ $= 5 - 2 + 8 - 5 $ $= 3 + 3$ $= 6$	
point x1, y1 (2, 5)	mean3 x2, y2 (1, 2)
$\rho(a, b) = x_2 - x_1 + y_2 - y_1 $ $\rho(\text{point}, \text{mean2}) = x_2 - x_1 + y_2 - y_1 $ $= 1 - 2 + 2 - 5 $ $= 1 + 3$ $= 4$	

ما جدول به صورت زیر پر می کنیم. چون فاصله از مرکز خوشه سوم کمترین است دومین نمونه به خوشه سوم تعلق می یابد.

Iteration 1

		(2, 10)	(5, 8)	(1, 2)	
	Point	Dist Mean 1	Dist Mean 2	Dist Mean 3	Cluster
A1	(2, 10)	0	5	9	1
A2	(2, 5)	5	6	4	3
A3	(8, 4)				
A4	(5, 8)				
A5	(7, 5)				
A6	(6, 4)				
A7	(1, 2)				
A8	(4, 9)				

بنابراین نمونه دوم به خوشه ۳ تعلق می یابد:

Cluster 1
(2, 10)

Cluster 2

Cluster 3
(2, 5)

همانند دو نمونه بالا بقیه جدول نیز پر می کنیم.

Iteration 1

		(2, 10)	(5, 8)	(1, 2)	
	Point	Dist Mean 1	Dist Mean 2	Dist Mean 3	Cluster
A1	(2, 10)	0	5	9	1
A2	(2, 5)	5	6	4	3
A3	(8, 4)	12	7	9	2
A4	(5, 8)	5	0	10	2
A5	(7, 5)	10	5	9	2
A6	(6, 4)	10	5	7	2
A7	(1, 2)	9	10	0	3
A8	(4, 9)	3	2	10	2

بنابراین ۱ نمونه به خوشه ۱، ۵ نمونه به خوشه ۲ و ۲ نمونه به خوشه ۳ تعلق می یابد:

Cluster 1
(2, 10)

Cluster 2
(8, 4)
(5, 8)
(7, 5)
(6, 4)
(4, 9)

Cluster 3
(2, 5)
(1, 2)





سپس ما نیاز داریم که مراکز خوشه ها (میانگین) را دوباره محاسبه کنیم. ما میانگین نمونه های درون خوشه ها را محاسبه می کنیم:

Cluster 1: $2/1, 10/1 = (2, 10)$

Cluster 2: $((8+5+7+6+4)/5, (4+8+5+4+9)/5) = (6, 6)$

Cluster 3: $((2+1)/2, (5+2)/2) = (1.5, 3.5)$

مراکز اولیه و مراکز جدید برای تکرار ۱ در شکل زیر نمایش داده شده است. مراکز اولیه با گلوله‌های قرمز و مراکز جدید با علامت * قرمز نشان داده شده است.



تکرار اول تمام شد. در تکرار دوم، سوم و ... دوباره کارهای بالا با مراکز جدید انجام می‌شود و هر بار مراکز جدید محاسبه می‌شود. الگوریتم تا زمانی ادامه می‌دهیم که در دو تکرار متوالی مراکز تغییر پیدا نکند. شکل زیر نتایج تکرار دوم را نشان می‌دهد:

